⚡ CLAUTRON OneClick — Relatório Completo de Evolução & Roadmap de Versões

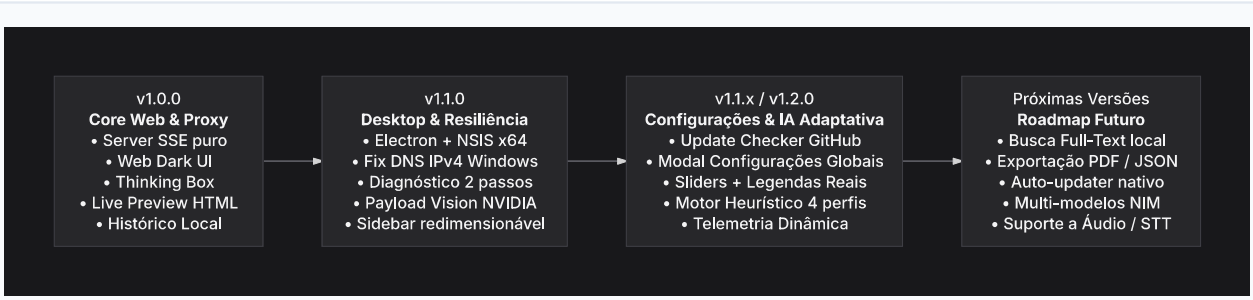
Autor: Felipe Monroe
Repositório: felipeptxa/clautron
Licença: MIT
Modelo Principal: NVIDIA Nemotron 3.5 Super VL 120B (`nvidia/nemotron-3.5-super-vl-120b-a12b`)
Data do Relatório: 05 de Novembro de 2026

Executive Summary

O **CLAUTRON OneClick** nasceu com o objetivo de oferecer uma estação desktop de alta performance para o modelo multimodal com raciocínio profundo da NVIDIA (**Nemotron 3.5 Super VL 120B**), sem requerer configurações complexas de ambiente Python, compilação de bibliotecas ou dependências locais pesadas de IA.

Através de uma arquitetura leve baseada em **Node.js nativo (zero dependências no backend)** e **Electron**, o software oferece streaming em tempo real via Server-Sent Events (SSE), suporte a visão computacional, sandbox de execução de código (Live Preview), inspeção de pensamento (Chain-of-Thought), central de hiperparâmetros e um motor heurístico adaptativo local.

🗺️ Linha do Tempo e Visão Geral das Versões



📦 Detalhamento Técnico Versão por Versão

1. Versão 1.0.0 — Fundação do Core e Web UI Local

A primeira versão estabeleceu os alicerces de comunicação com a NVIDIA NIM e a experiência visual do usuário.

Componente	Implementação	Finalidade / Benefício
Proxy Local (`server.js`)	Servidor HTTP nativo Node.js (`http` , `https` , `fs` , `path`)	Elimina dependência de Express ou frameworks pesados; inicialização instantânea e consumo mínimo de RAM.
Streaming SSE	Proxy bidirecional Server-Sent Events (`/api/messages`)	Transmissão de tokens e raciocínio em tempo real com baixa latência para o navegador.
Chain-of-Thought (CoT)	Parser de `<thought>` e campo nativo `reasoning_content`	Caixa colapsável `<details class="thinking-box">` destacando o raciocínio profundo da IA.
Interface Dark Theme	CSS moderno com paleta escura (`#131314` , `#18191a` , `#282a2c`)	Ergonomia visual prolongada inspirada no Claude/Antigravity, sem poluição de menus.
Formatador de Markdown	Integração via CDN de `marked.js` e `highlight.js`	Renderização rica de textos, tabelas, listas e blocos de código com destaque de sintaxe escuro.
Live HTML Preview	`iframe` com sandbox de isolamento e script de injeção	Permite testar e executar artefatos HTML, CSS e JavaScript gerados pela IA sem sair da aplicação.
Histórico de Conversas	Persistência local no navegador via `localStorage` (`nemotron_chat_sessions_v1`)	Múltiplas sessões independentes, renomeação de tópicos, exclusão e exportação individual para `.md` .
Entrada de Anexos	Suporte a arquivos de código e imagens via Drag-and-Drop e `Ctrl+V`	Inclusão de código fonte e captura de tela diretamente no prompt do usuário.
Scripts de Inicialização	`START CLAUTRON.bat` e `run.sh`	Permite ao usuário iniciar o app com um duplo clique no Windows ou Linux.

2. Versão 1.1.0 — Desktop Nativo, Robustez de Rede e Diagnóstico

A versão 1.1 transformou a aplicação Web em um aplicativo desktop nativo para Windows e resolveu desafios de rede e compatibilidade com a API da NVIDIA.

🔧 **Principais Marcos Técnicos:**

1. **Migração para Electron Desktop:**
   - Adicionados `main.js`, `electron@^40.8.0` e `electron-builder@^26.0.2`.
   - Criação do instalador executável `CLAUTRON OneClick Setup 1.1.0.exe` (NSIS x64).
   - Atalho de desenvolvedor **F12** integrado para depuração e inspeção do DOM.
   - Janela frameless customizada (título nativo, controle de tamanho mínimo e preservação de estado).
2. **Correções de Conectividade e Protocolo:**
   - **Fix IPv6 Dual-Stack no Windows:** Adicionado `dns.setDefaultResultOrder('ipv4first')` em `main.js` e `server.js`, eliminando congelamentos de DNS causados por interfaces IPv6 inativas.
   - **Fix do Streaming Abort Prematuro:** Substituição de `req.on('close')` por `res.on('close')` no proxy. O evento anterior disparava assim que o cliente terminava de enviar o corpo POST, cancelando a requisição à NVIDIA antes do primeiro token chegar.
   - **Padronização Multimodal NVIDIA:** Conversão do payload de imagens para o formato estrito `{ type: "image_url", image_url: { url: "data:...; base64,..." } }`, compatibilizando o upload de capturas com o padrão aceito pelo Nemotron Vision.
3. **Botão de Diagnóstico de 2 Passos no Cabeçalho (`/api/test-nvidia`):**
   - **Passo 1:** Validação da chave `nvapi-...` e conectividade contra `https://integrate.api.nvidia.com/v1/models` (timeout 15s).
   - **Passo 2:** Teste de inferência real de 1 token sem streaming (timeout 20s).
   - Indicadores visuais dinâmicos no cabeçalho: `Verificando...`, `NVIDIA OK ✓` ou mensagens precisas de erro (ex: HTTP 401 para chave inválida, HTTP 403 para permissão e 504 para timeout).
4. **Refinamentos de Interface:**
   - Barra lateral (`aside`) retrátil com suporte a redimensionamento manual arrastando a borda (drag-to-resize com limites seguros entre 180px e 520px).
   - Licença MIT formalizada e README bilíngue (Português e Inglês).

3. Versão 1.1.x / v1.2.0 (Ciclo Recente) — IA Adaptativa & Central de Configurações

Nesta etapa, o CLAUTRON recebeu inteligência heurística local, permitindo que a própria aplicação module seus hiperparâmetros de acordo com o contexto da conversa.

🚀 Recursos Implementados:

A. Verificador Automático de Atualizações do GitHub

- Consulta assíncrona leve à API pública: `https://api.github.com/repos/felipeptxa/clautron/releases/latest`.
- Comparação semântica de versões (`1.1.0` vs tag mais recente).
- Badge animado pulsante no cabeçalho: 🟢 `Atualização Disponível`.
- Modal de atualização com exibição do Changelog oficial formatado em Markdown e botão direto para download do release.
- Operação 100% silenciosa caso o usuário esteja offline ou a API atinja rate-limit.

B. Central de Configurações Globais (Engrenagem ⚙️)

- Transformação do antigo modal de chave em uma central completa dividida em 3 seções:
    1. **Chave API NVIDIA (`nvapi-...`):** Campo seguro com preservação no `localStorage`.
    2. **Custom System Prompt Permanente:** Textarea expansível para definir instruções de comportamento que persistem em todas as conversas.
    3. **Hiperparâmetros de Inferência com Sliders e Legenda em Tempo Real:**
        - **Temperature (0.0 a 1.5, step 0.05):** Feedback em tempo real:
            - *0.00 – 0.39:* "🎯 Respostas ultra determinísticas e precisas (ideal para código, lógica pura e refatoração)".
            - *0.40 – 0.89:* "⚖️ Equilíbrio padrão da indústria (respostas balanceadas e contextuais)".
            - *0.90 – 1.50:* "🎨 Mais criativo e exploratório (ideal para brainstorming, redação e conceitos visuais)".
        - **Top-P (0.1 a 1.0, step 0.05):** Filtro de amostragem por probabilidade cumulativa.
        - **Max Output Tokens (512 a 8192, step 256):** Orçamento máximo de resposta do modelo.
    4. **Botão "Restaurar Padrões":** Reseta os sliders para 0.70, 0.95 e 4096 com um clique.

C. Motor Heurístico Adaptativo ("🤖 Automático")

Um classificador local de intenção e complexidade analisa o prompt e anexos do usuário antes do envio (`detectPromptComplexity`), aplicando automaticamente o perfil ideal:

Categoria	Critérios de Detecção	Temp	Top-P	Max Tokens	Thinking (CoT)	Tag / Telemetria
Código / Técnico	Blocos ```, arquivos de código (.js, .py, etc.), termos como `refatore`, `função`, `bug`, `api`, `sql`	**0.20**	**0.90**	**8192**	`true`	`Auto (Código)`
Criativo / Brainstorm	Palavras como `crie uma história`, `roteiro`, `brainstorm`, `slogan`, `poema`, `copy`	**1.05**	**0.98**	**4096**	`false`	`Auto (Criativo)`
Rápido / Factual	Texto curto (< 70 caracteres), sem código, saudações (`olá`, `bom dia`) e perguntas diretas (`o que é`, `defina`)	**0.30**	**0.85**	**1536**	`false`	`Auto (Rápido)`
Profundo / Analítico	Prompts longos (> 200 caracteres), comparações (`compare`, `analise`, `arquitetura`, `prós e contras`)	**0.60**	**0.95**	**6144**	`true`	`Auto (Profundo)`

- **Feedback Visual no Modal:** Quando no modo Automático, os sliders ficam com opacidade suave (`.auto-mode`) e é exibido o card explicativo "*Parâmetros modulados automaticamente a cada pergunta*". Se o usuário arrastar qualquer slider manualmente, o preset muda automaticamente para "🛠️ **Manual**".
- **Telemetria de Rodapé:** Cada balão de resposta registra o perfil adotado: ex. `Effort: Auto (Código)`.
- **Suporte no Proxy (`server.js`):** Repassa `temperature`, `top_p`, `max_tokens` e a flag booleana `chat_template_kwargs: { enable_thinking: isThinking }` para a API NVIDIA.

🧬 Matriz Comparativa da Evolução

Recurso	v1.0.0	v1.1.0	v1.1.x / v1.2.0
Ambiente de Execução	Navegador Web	Desktop Electron (NSIS x64)	Desktop Electron + Web
Modelo NIM	Nemotron 3.5 Super VL	Nemotron 3.5 Super VL	Nemotron 3.5 Super VL
Diagnóstico de Conexão	❌ Não	✅ 2 Passos (Rede + Inferência)	✅ 2 Passos com Feedback de Erro
Suporte Multimodal	Básico	✅ Formato Estrito NVIDIA	✅ Formato Estrito NVIDIA
Sidebar Redimensionável	❌ Fixa	✅ Drag-to-Resize	✅ Drag-to-Resize
Checagem de Atualização	❌ Não	❌ Não	✅ GitHub Releases API com Modal
Custom System Prompt	❌ Não	❌ Não	✅ Permanente no LocalStorage
Ajuste de Hiperparâmetros	❌ Fixo no proxy	❌ Fixo no proxy	✅ Sliders manuais + Legendas vivas
Seleção de Esforço	Manual (Low/Med/High)	Manual (Low/Med/High)	✅ Modo Adaptativo Heurístico (4 perfis)
Telemetria na Mensagem	Estática	Estática	✅ Dinâmica por Perfil Heurístico

🎯 Roadmap Estratégico para Próximas Versões

Com a base técnica estabilizada, este é o catálogo priorizado de implementações para as próximas versões:

🌟 Versão 1.2.0 (Foco: Produtividade, Busca & Exportação)

- **Busca Global no Histórico:** Barra de pesquisa em tempo real na barra lateral para localizar conversas antigas por palavras-chave ou trechos de código.
- **Exportação em Múltiplos Formatos:**

    - Exportar conversa completa em **PDF** formatado (com suporte a quebra de página limpa de código).
    - Exportar em **JSON estruturado** para backup e importação entre máquinas.
- **Importação de Sessões:** Permitir restaurar backups de histórico com um clique.
- **Limpeza de Contexto Inteligente:** Botão de "Limpar Histórico Desta Sessão" mantendo o System Prompt ativo sem precisar criar uma nova conversa.

🚀 Versão 1.3.0 (Foco: Multi-Modelos & Experiência Avançada)

- **Seletor de Modelos NVIDIA NIM:**
    - Permitir alternar entre `nemotron-3.5-super-vl-120b`, `llama-3.1-405b-instruct`, `deepseek-r1` ou outros modelos disponíveis na conta do usuário.
- **Calculadora de Consumo de Tokens:**
    - Exibir contador aproximado de tokens consumidos na sessão e tempo de resposta (tokens/segundo).
- **Atalhos de Teclado Globais (Keybindings):**
    - `Ctrl + N`: Nova conversa.
    - `Ctrl + K`: Abrir busca de conversas.
    - `Ctrl + ,`: Abrir Configurações.
    - `Ctrl + Shift + S`: Alternar exibição da barra lateral.

🛡️ Versão 1.4.0 (Foco: Atualização Silenciosa & Áudio)

- **Auto-Updater Integrado:** Integração com `electron-updater` para baixar e instalar atualizações em segundo plano sem exigir download manual do `.exe`.
- **Entrada de Voz (Speech-to-Text):** Integração com Whisper local ou via API para ditar prompts pelo microfone.
- **Modo Janela Flutuante (Picture-in-Picture / Always-on-Top):** Janela compacta fixada sobre outros programas para consultas rápidas enquanto programa.

> TIP
>
> **Como Exportar Este Relatório:** Este documento pode ser exportado diretamente para Markdown (`.md`) ou impresso como PDF a partir do visualizador do seu ambiente. Ele serve como documentação de entrega da versão atual e base de especificação para as próximas issues e sprints do repositório.